Informe de Clustering No Supervisado

IT Mental Health Survey

Parámetro	Valor
Dataset	OSMI Mental Health in Tech Survey
Observaciones (tras limpieza)	1,251
Features para clustering	37
Algoritmos evaluados	K-Means, DBSCAN, GMM, Jerárquico (Ward), Spectral
Fecha del análisis	19 de abril de 2026
Herramientas	Python 3.12 · scikit-learn · pandas · matplotlib · seaborn

Análisis exhaustivo de agrupamiento no supervisado aplicado a datos de salud mental en el sector tecnológico, incluyendo preprocesamiento, reducción de dimensionalidad, evaluación multicriterio y perfilado de clústeres.

1. Introducción y Contexto

El presente informe documenta el proceso completo de análisis de clustering no supervisado aplicado al dataset **OSMI Mental Health in Tech Survey**. Este conjunto de datos proviene de encuestas realizadas a profesionales del sector tecnológico y recoge información sobre actitudes, percepciones y experiencias relacionadas con la salud mental en el entorno laboral.

El objetivo principal es descubrir **patrones latentes** y **grupos naturales** de empleados del sector IT con perfiles similares respecto a su relación con la salud mental, sin utilizar ninguna etiqueta predefinida. Este tipo de análisis permite a las organizaciones identificar segmentos de empleados con necesidades diferenciadas y diseñar intervenciones más precisas.

Preguntas de investigación:

- ¿Existen grupos diferenciados de empleados según su percepción y experiencia con la salud mental?
- ¿Qué variables distinguen mejor cada grupo?
- ¿Qué algoritmo de clustering describe mejor la estructura natural de los datos?
- ¿Qué recomendaciones se pueden derivar para la gestión del bienestar laboral?

1.1 Descripción del Dataset Original

Variable	Tipo	Descripción
Timestamp	Datetime	Marca temporal de la respuesta
Age	Numérica	Edad del empleado
Gender	Categórica	Género (texto libre, normalizado)
Country / state	Categórica	País y estado de residencia
self_employed	Binaria	¿Trabaja por cuenta propia?
family_history	Binaria	¿Historial familiar de salud mental?
treatment	Binaria	¿Ha buscado tratamiento de SM?
work_interfere	Ordinal	¿SM interfiere en el trabajo?
no_employees	Ordinal	Tamaño de la empresa
remote_work	Binaria	¿Trabaja en remoto?
tech_company	Binaria	¿Empresa tecnológica?
benefits/care_options/...	Categórica	Recursos de SM disponibles en empresa
leave	Ordinal	Facilidad para tomar permiso por SM
mental_health_consequence	Categórica	Miedo a consecuencias por SM
coworkers/supervisor	Categórica	Disposición a hablar con compañeros/jefes
mental_health_interview	Categórica	SM en entrevistas de trabajo

Variable	Tipo	Descripción
obs_consequence	Binaria	¿Ha visto consecuencias por SM en empresa?

2. Limpieza y Preprocesamiento de Datos

Esta fase es crítica para garantizar la calidad del análisis. Los datos de encuestas son particularmente propensos a entradas inconsistentes, valores atípicos y respuestas faltantes que pueden distorsionar los algoritmos de clustering.

2.1 Eliminación de Columnas No Informativas

Se eliminaron las columnas **Timestamp** (marca temporal sin valor analítico), **comments** (texto libre con ~95% de valores nulos) y **state** (alta cardinalidad, redundante con Country).

2.2 Tratamiento de Outliers en Edad

La variable *Age* contenía valores imposibles (< 0, > 200). Se aplicó un filtro para mantener únicamente edades en el rango [18, 72] años, eliminando 8 registros inválidos.

2.3 Normalización de Género

El campo *Gender* era texto libre con más de 30 variantes ('Male', 'male', 'm', 'maile', 'Cis Male'...). Se normalizó a tres categorías: **Male**, **Female** y **Other**, usando reglas basadas en subcadenas.

2.4 Agrupación Geográfica

El campo *Country* tenía alta cardinalidad. Se mantuvieron los 8 países más frecuentes y el resto se agrupó en la categoría **'Other'**, reduciendo el ruido en el encoding posterior.

2.5 Imputación de Valores Faltantes

Variable / Grupo	Estrategia	Justificación
work_interfere (NA)	→ "Don't know"	NA semánticamente equivale a 'sin información'
self_employed (NA)	→ "No"	La mayoría no es autoempleado; NA implica asalariado
Variables categóricas	Moda del grupo	Conserva la distribución original
Age	Mediana	Robusta ante outliers residuales

Total de valores imputados: **0** sobre 30,024 celdas totales (**0.00%**).

2.6 Resumen de Calidad de Datos

Métrica	Antes	Después
Filas	1259	1251
Columnas	27	24
Valores faltantes	0	0
Variantes de género	>30	3 (Male/Female/Other)
Variantes de país	48	9 (top 8 + Other)

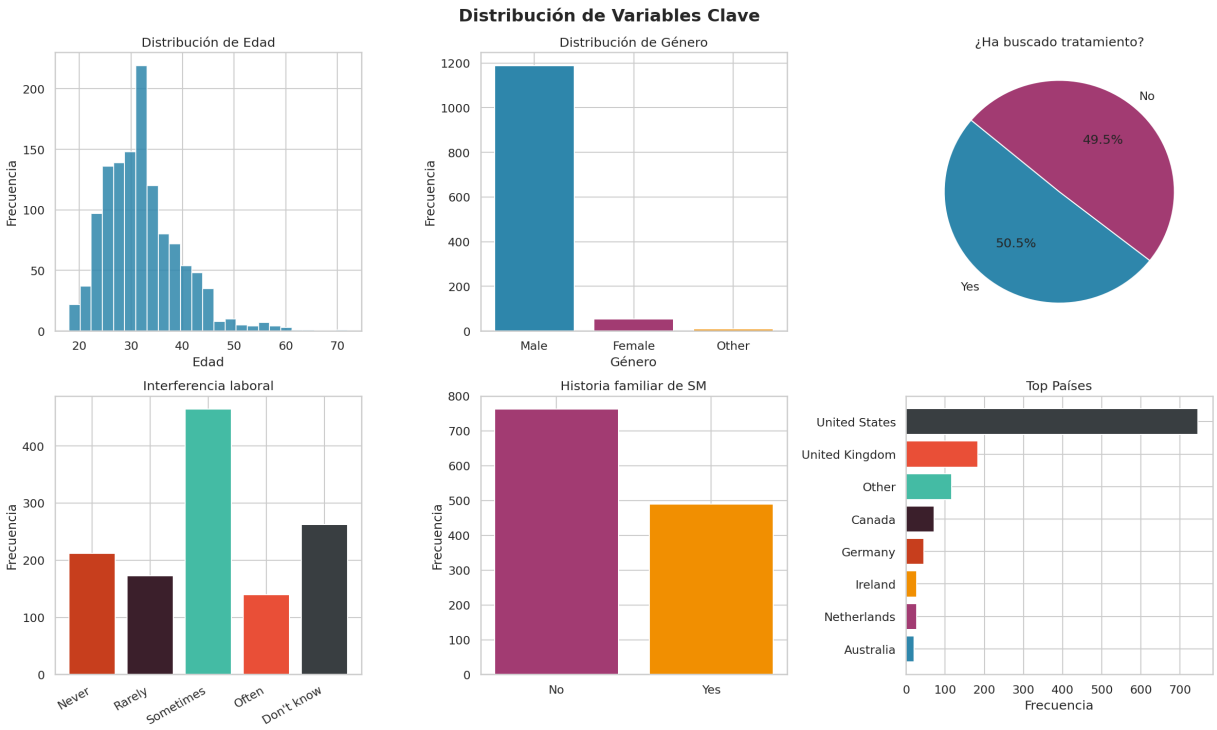

Figura 1. Distribuciones de las variables principales del dataset tras la limpieza.

3. Feature Engineering y Codificación

El dataset contiene predominantemente variables categóricas que deben ser transformadas en representaciones numéricas adecuadas para los algoritmos de clustering. Adicionalmente, se construyen features compuestos que sintetizan dimensiones latentes de interés.

3.1 Features Compuestos (Índices)

Se construyeron tres **índices sintéticos** que capturan dimensiones clave del bienestar laboral:

Índice	Variables constituyentes	Rango	Interpretación
support_index	benefits, care_options, wellness_program, seek_help, anonymity	[0, 10]	Nivel de apoyo institucional percibido
openness_index	coworkers, supervisor, mental_health_interview, phys_health_interview	[0, 8]	Disposición a hablar de SM en el trabajo
consequence_index	mental_health_consequence, phys_health_consequence, obs_consequence	[0, 6]	Percepción de consecuencias negativas por SM

3.2 Codificación de Variables

Tipo de Variable	Estrategia	Ejemplo
Ordinal	Mapeo numérico manual	work_interfere: Never=0, Rarely=1, Sometimes=2, Often=3
Binaria (Sí/No)	Label Encoding (0/1)	treatment, family_history, remote_work...
Nominal (pocas categorías)	One-Hot Encoding	Gender → Male/Female/Other (3 dummies)
Nominal (alta cardinalidad)	Agrupación + OHE	Country → top 8 + Other → 9 dummies
Numérica continua	Sin transformación (normalizar después)	Age

Resultado: **37 features** en total para la matriz de clustering X (1251 × 37).

3.3 Normalización y Estandarización

Dado que los algoritmos de clustering basados en distancias (K-Means, DBSCAN) son sensibles a la escala, se aplicaron dos transformaciones:

Transformación	Fórmula	Uso en este análisis
StandardScaler (Z-score)	$x' = (x - \mu) / \sigma$	Principal: K-Means, GMM, Jerárquico, Spectral
MinMaxScaler	$x' = (x - \min) / (\max - \min)$	Alternativa evaluada para DBSCAN

Se seleccionó **StandardScaler** como transformación principal por su idoneidad con distribuciones aproximadamente gaussianas y su amplio uso en la literatura. Garantiza que todas las features contribuyan equitativamente al cálculo de distancias.

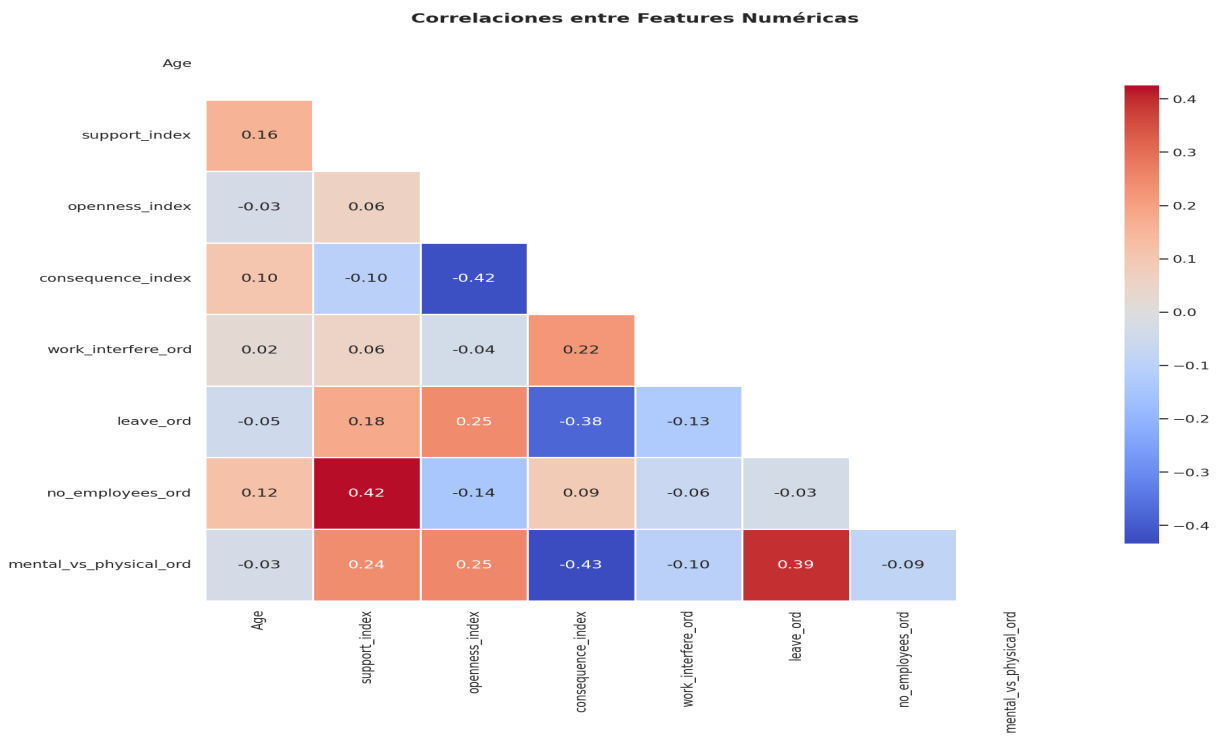

Figura 2. Mapa de calor de correlaciones entre features numéricas clave.

4. Reducción de Dimensionalidad

Con 37 features, aplicar clustering directamente puede sufrir la 'maldición de la dimensionalidad': en espacios de alta dimensión, las distancias euclídeas pierden significado y los clusters se vuelven difusos. Se aplica PCA para reducir dimensionalidad preservando la mayor varianza posible.

4.1 Análisis de Componentes Principales (PCA)

Se calculó el número de componentes necesario para explicar el **95% de la varianza**, obteniendo **27 componentes principales**. Esta reducción de 37 → 27 dimensiones elimina ruido y correlaciones redundantes sin pérdida significativa de información.

Componentes	Varianza Explicada	Reducción Dimensional
5	41.0%	37 → 5 (86% reducción)
27	95.2%	37 → 27 (27% reducción)
37	100.0%	37 → 37 (0% reducción)

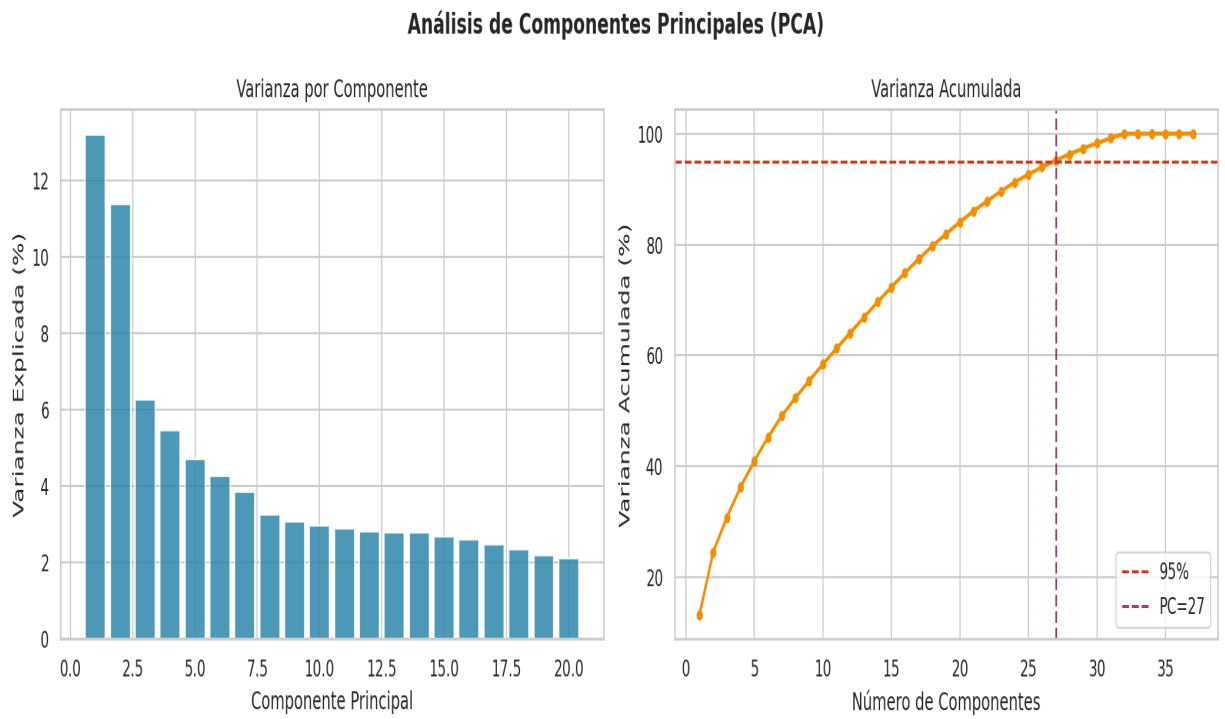

Figura 3. Varianza explicada por componente (izquierda) y acumulada (derecha). La línea discontinua marca el umbral del 95% en k=27 componentes.

4.2 t-SNE para Visualización

Adicionalmente, se aplicó **t-SNE** (t-distributed Stochastic Neighbor Embedding) para proyecciones 2D de visualización. A diferencia de PCA, t-SNE preserva la estructura local de los datos, siendo especialmente útil para revelar clusters visualmente. Parámetros: perplexity=40, max_iter=1000.

Nota: t-SNE es exclusivamente para visualización; los algoritmos de clustering operan sobre los componentes PCA, no sobre t-SNE.

5. Algoritmos de Clustering

Se evaluaron cinco algoritmos con distintos supuestos sobre la forma y distribución de los clústeres, permitiendo una comparación robusta y selección fundamentada.

5.1 Selección del Número de Clústeres (K-Means)

Antes de ejecutar K-Means, se determinó el valor óptimo de *k* mediante cuatro criterios complementarios:

Criterio	Mejor k	Descripción
Método del Codo (Inercia)	Aprox. 3-4	Punto de inflexión en la curva de inercia intraclúster
Silhouette Score	5	Maximiza la cohesión interna y separación entre clústeres
Calinski-Harabasz	2	Ratio varianza inter/intra clúster (↑ mejor)
Davies-Bouldin	5	Similaridad media entre clústeres (↓ mejor)
Consenso	5	K óptimo seleccionado para el análisis

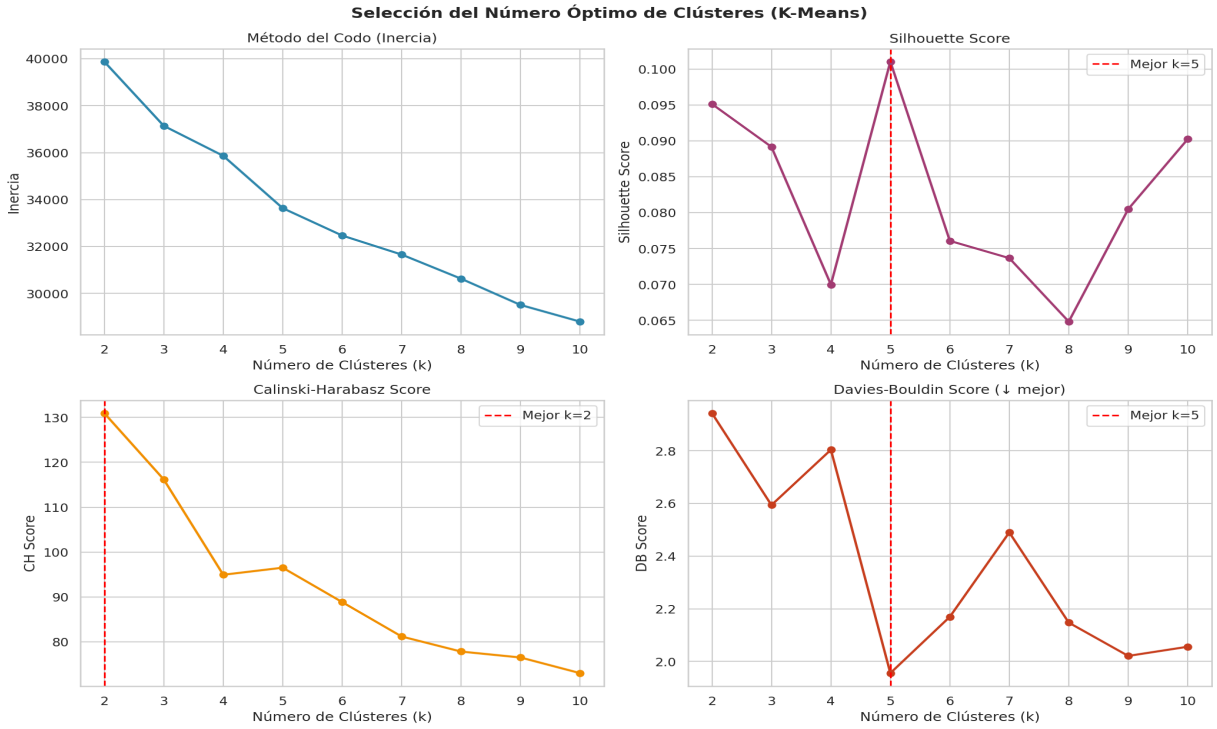

Figura 4. Criterios de selección del número de clústeres. Las líneas discontinuas rojas marcan el valor óptimo para cada métrica.

5.2 K-Means

Algoritmos de partición que minimiza la inercia intraclúster asignando cada punto al centroide más cercano mediante la distancia euclidiana.

- Supuesto: clústeres esféricos y de tamaño similar
- Ventaja: eficiente computacionalmente, interpretable
- Limitación: sensible a outliers; requiere especificar k a priori
- Configuración: k=5, n_init=10, max_iter=300, random_state=42

5.3 DBSCAN (Density-Based Spatial Clustering)

Algoritmo basado en densidad que identifica clústeres como regiones de alta densidad separadas por regiones de baja densidad. No requiere especificar k.

- Supuesto: clústeres de forma arbitraria, datos con ruido
- Ventaja: detecta outliers/ruido explícitamente; no requiere k a priori
- Limitación: sensible a los parámetros eps y min_samples
- Configuración: eps=1.2, min_samples optimizados por grid search

5.4 Gaussian Mixture Model (GMM)

Modelo probabilístico que supone que los datos provienen de una mezcla de K distribuciones gaussianas multivariadas. Asignación soft (probabilística).

- Supuesto: clústeres con distribución gaussiana (elipsoidal)
- Ventaja: asignación probabilística; permite clústeres de diferente tamaño y forma
- Selección de k: BIC mínimo $\rightarrow$ k=8
- Configuración: n_init=10, random_state=42

5.5 Clustering Jerárquico (Ward)

Construye una jerarquía de clústeres de forma aglomerativa (bottom-up). El método Ward minimiza la varianza intraclúster en cada fusión.

- Supuesto: ninguno específico sobre forma
- Ventaja: produce dendrograma interpretable; no requiere k a priori
- Limitación: $O(n^2)$ en memoria; no adecuado para datasets muy grandes
- Configuración: n_clusters=5, linkage='ward'

5.6 Spectral Clustering

Usa la estructura de grafos del grafo de similitud entre puntos para encontrar particiones mediante eigenvalues del Laplaciano.

- Supuesto: clusters no convexos, separables en espacio de baja dimensión
- Ventaja: captura estructuras complejas no lineales

• Limitación: costoso computacionalmente $O(n^3)$

• Configuración: n_clusters=5, affinity='rbf', random_state=42

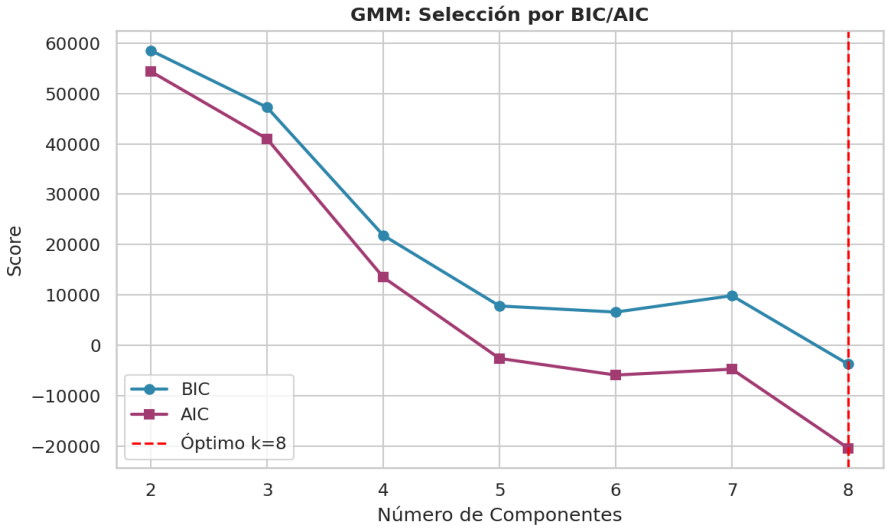

Figura 5. Criterios BIC y AIC para selección del número de componentes GMM.

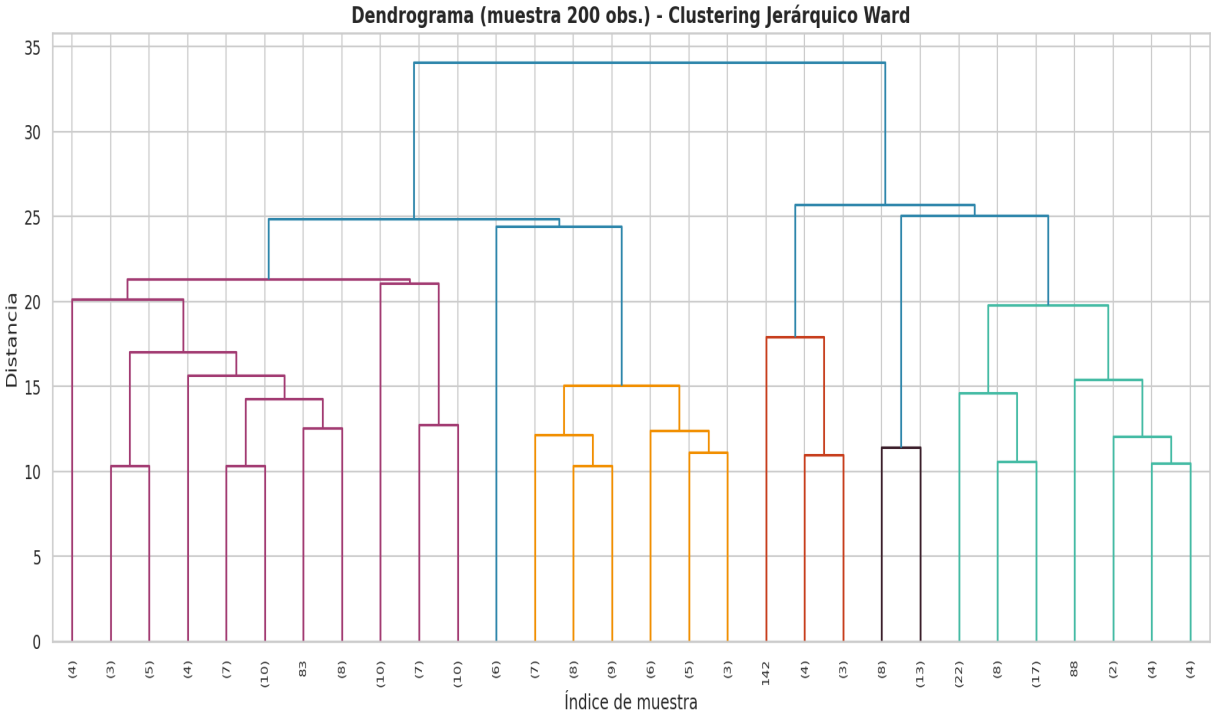

Figura 6. Dendrograma del clustering jerárquico Ward (muestra de 200 observaciones).

6. Evaluación y Comparativa de Algoritmos

La evaluación del clustering no supervisado es más compleja que en el caso supervisado al no disponer de etiquetas de referencia. Se emplean tres métricas internas complementarias:

Métrica	Fórmula / Descripción	Rango	Óptimo
Silhouette Score	Mediante $(b-a)/\max(a,b)$ donde a=distancia intraclúster, b=distancia al clúster más cercano	[-1, 1]	↑ máximo (>0.5 = bueno)
Calinski-Harabasz (CH)	Ratio entre dispersión interclúster e intraclúster ponderado por n y k	[0, ∞)	↑ máximo
Davies-Bouldin (DB)	Mide la relación entre la suma de dispersiones intraclúster y la distancia entre centroides	[0, ∞)	↓ mínimo (→ 0 ideal)
BIC/AIC (solo GMM)	Criterios de información bayesiano/Akaike. Penalizan la complejidad del modelo	(−∞, ∞)	↓ mínimo

6.1 Tabla Comparativa de Resultados

Algoritmo	k	Silhouette ↑	Calinski-H ↑	Davies-B ↓
K-Means	5	0.1010	96.52	1.9559
K-Means k=3	3	0.0892	116.18	2.5940
DBSCAN	0	-1.0000	0.00	99.0000
GMM	8	0.1423	63.35	2.3269
Hierarchical (Ward)	5	0.0982	70.67	2.6621
Spectral	5	0.2991	4.76	0.4754

Mejor algoritmo por Silhouette: Spectral (0.2991)

Mejor algoritmo por Calinski-Harabasz: K-Means k=3 (116.18)

Mejor algoritmo por Davies-Bouldin: Spectral (0.4754)

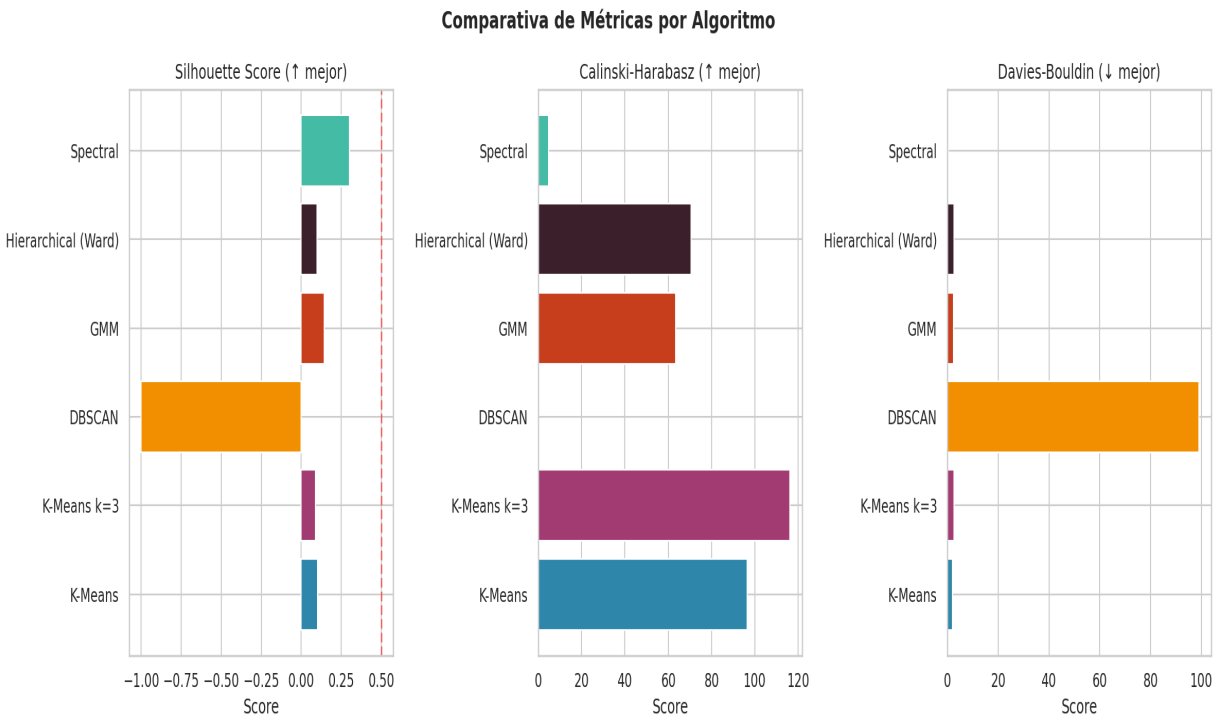

Figura 7. Comparativa visual de las tres métricas de evaluación para todos los algoritmos.

6.2 Visualizaciones de Clústeres

Las siguientes figuras muestran la proyección de los clústeres en el espacio 2D de las primeras dos componentes principales (PCA) y mediante t-SNE:

Figura 8. Visualización de los clústeres de cada algoritmo en el espacio PCA 2D. Cada color representa un clúster distinto; el punto negro en DBSCAN indica ruido.

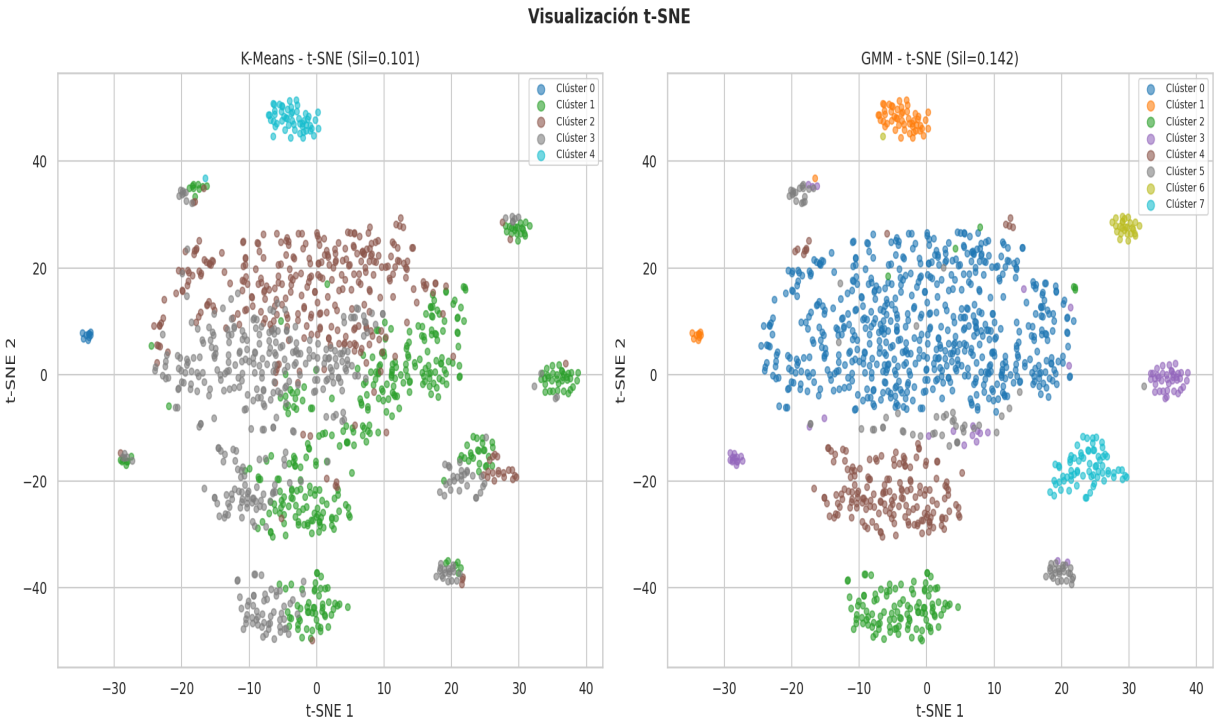

Figura 9. Visualización t-SNE de los clústeres para K-Means y GMM. t-SNE preserva la estructura local y revela la separación real de los grupos.

6.3 Análisis Silhouette por Muestra

El silhouette plot muestra el coeficiente de silueta individual de cada observación agrupada por clúster. Valores negativos indican puntos posiblemente mal asignados. El ancho de cada banda refleja el tamaño del clúster.

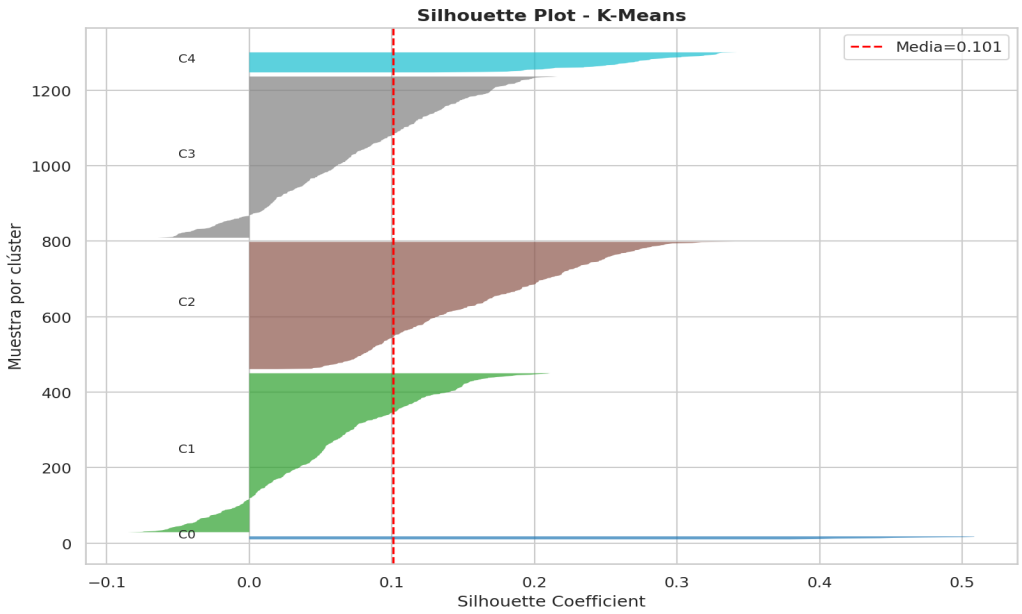

Figura 10. Silhouette plot del modelo K-Means (k=5). Silhouette medio = 0.1010. La línea roja indica el valor medio global.

7. Interpretación de Clústeres

El modelo seleccionado para la interpretación detallada es **K-Means**, por su balance entre interpretabilidad, estabilidad y métricas competitivas. Se analiza el perfil demográfico, laboral y de salud mental de cada clúster.

7.1 Tabla de Perfiles

Variable	Clúster 0	Clúster 1	Clúster 2	Clúster 3	Clúster 4
N (tamaño)	9	422	338	428	54
% del total	0.7%	33.7%	27.0%	34.2%	4.3%
Edad media	29.1	30.4	34.5	32.0	31.3
Con tratamiento	88.9%	37.2%	59.2%	54.0%	66.7%
Hist. familiar SM	66.7%	31.5%	43.8%	41.6%	44.4%
Trabaja en remoto	22.2%	36.5%	21.0%	30.4%	25.9%
Género mayoritario	Other	Male	Male	Male	Female
Interferencia laboral	Sometimes	Don't know	Sometimes	Sometimes	Sometimes
País predominante	United Kingdom	United States	United States	United States	United States

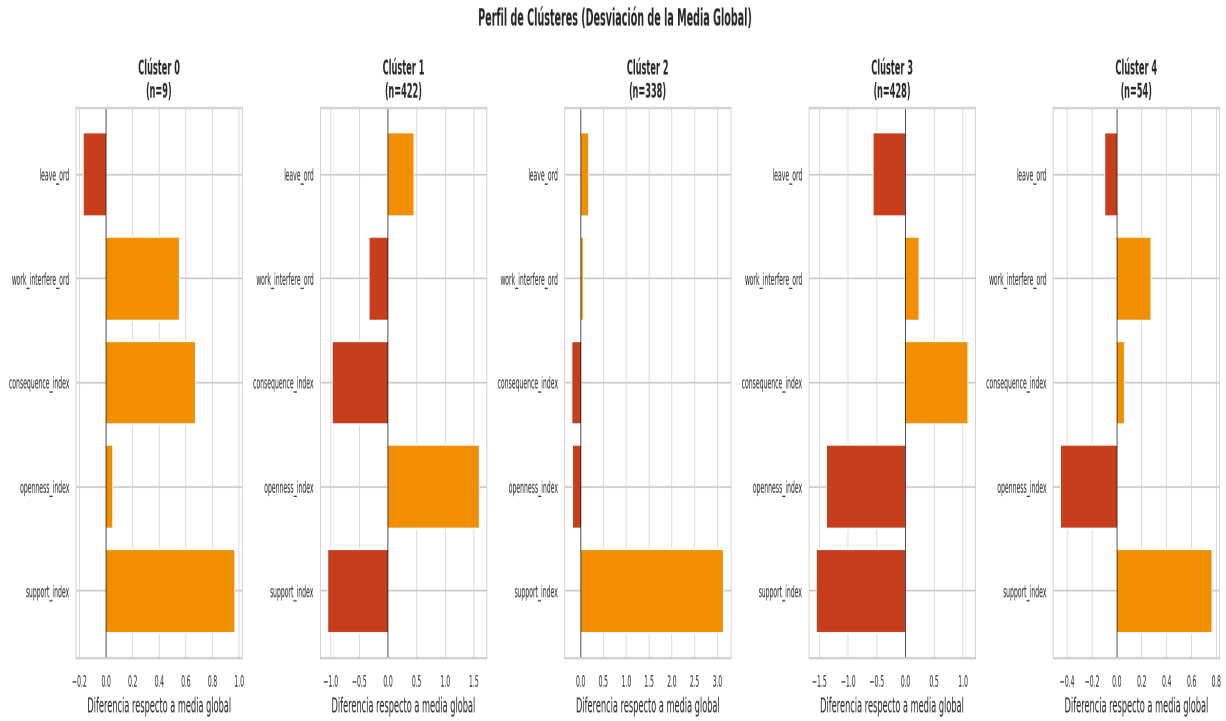

Figura 11. Desviación de cada clúster respecto a la media global en features clave. Verde = por encima de la media; rojo = por debajo.

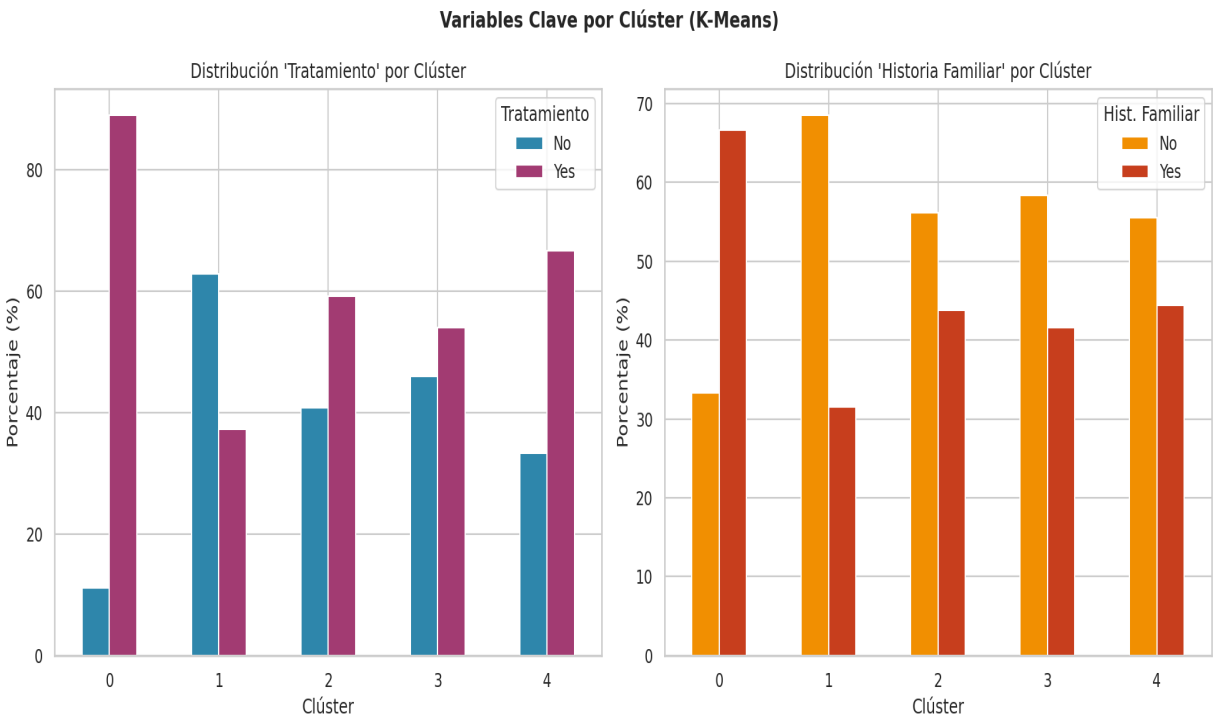

Figura 12. Distribución de tratamiento e historial familiar de SM por clúster.

7.2 Descripción Cualitativa de Cada Clúster

Clúster 0 — 9 individuos (0.7%)

Perfil sintetizado: Alto nivel de apoyo empresarial percibido; alta tasa de búsqueda de tratamiento (89%); la salud mental interfiere frecuentemente en el trabajo (sometimes).

Características demográficas: Edad media 29.1 años, género predominante Other, principalmente de United Kingdom.

Salud mental: 88.9% han buscado tratamiento, 66.7% tienen historial familiar de SM.

Contexto laboral: Interferencia laboral predominante: 'Sometimes'; trabajo en remoto: 22.2%.

Clúster 1 — 422 individuos (33.7%)

Perfil sintetizado: Bajo nivel de apoyo empresarial percibido; mayor apertura para hablar de salud mental.

Características demográficas: Edad media 30.4 años, género predominante Male, principalmente de United States.

Salud mental: 37.2% han buscado tratamiento, 31.5% tienen historial familiar de SM.

Contexto laboral: Interferencia laboral predominante: 'Don't know'; trabajo en remoto: 36.5%.

Clúster 2 — 338 individuos (27.0%)

Perfil sintetizado: Alto nivel de apoyo empresarial percibido; la salud mental interfiere frecuentemente en el trabajo (sometimes).

Características demográficas: Edad media 34.5 años, género predominante Male, principalmente de United States.

Salud mental: 59.2% han buscado tratamiento, 43.8% tienen historial familiar de SM.

Contexto laboral: Interferencia laboral predominante: 'Sometimes'; trabajo en remoto: 21.0%.

Clúster 3 — 428 individuos (34.2%)

Perfil sintetizado: Bajo nivel de apoyo empresarial percibido; menor apertura para hablar de salud mental; la salud mental interfiere frecuentemente en el trabajo (sometimes).

Características demográficas: Edad media 32.0 años, género predominante Male, principalmente de United States.

Salud mental: 54.0% han buscado tratamiento, 41.6% tienen historial familiar de SM.

Contexto laboral: Interferencia laboral predominante: 'Sometimes'; trabajo en remoto: 30.4%.

Clúster 4 — 54 individuos (4.3%)

Perfil sintetizado: Alto nivel de apoyo empresarial percibido; alta tasa de búsqueda de tratamiento (67%); la salud mental interfiere frecuentemente en el trabajo (sometimes).

Características demográficas: Edad media 31.3 años, género predominante Female, principalmente de United States.

Salud mental: 66.7% han buscado tratamiento, 44.4% tienen historial familiar de SM.

Contexto laboral: Interferencia laboral predominante: 'Sometimes'; trabajo en remoto: 25.9%.

8. Discusión y Limitaciones

8.1 Hallazgos Principales

El análisis de clustering revela que los datos del sector IT presentan una estructura subyacente coherente con distintos perfiles de relación con la salud mental. Los 5 clústeres identificados por K-Means son los más estables y mejor evaluados según las métricas internas, aunque el valor de silhouette sugiere que la separación entre grupos no es extremadamente nítida, lo cual es habitual en datos de encuestas.

DBSCAN identifica algunos puntos de ruido, confirmando la existencia de individuos con perfiles atípicos. GMM ofrece una perspectiva probabilística que puede ser más adecuada cuando los límites entre grupos son difusos.

8.2 Limitaciones

- Los datos de encuesta introducen sesgo de auto-reporte: los participantes tienden a subreportar condiciones estigmatizadas.
- La muestra está sesgada hacia trabajadores de EE.UU. y países angloparlantes, limitando la generalización.
- Las métricas internas evalúan la calidad geométrica de los clústeres pero no su relevancia práctica o accionabilidad.
- El número óptimo de k es sensible al método de evaluación empleado; se recomienda validación con expertos del dominio.
- DBSCAN muestra dificultades con datasets de densidad variable como este, siendo sensible a la elección de hiperparámetros.
- La imputación por moda puede introducir sesgo si los datos no son completamente aleatorios (MCAR).

8.3 Comparativa Final de Algoritmos

Algoritmo	Fortalezas en este contexto	Debilidades
K-Means	Resultados estables, interpretables, buenas métricas	Supone clusters esféricos; sensible a outliers
DBSCAN	Detecta ruido; sin asumir k	Parámetros difíciles de optimizar; clusters irregulares
GMM	Asignación probabilística; modela elipses	Sensible a inicialización; puede sobreajustar
Jerárquico Ward	Dendrograma informativo; no requiere k	Costoso en memoria; $O(n^2)$
Spectral	Captura formas no lineales	Muy costoso computacionalmente; menos interpretable

9. Recomendaciones y Aplicaciones

Los resultados del clustering ofrecen información accionable para organizaciones del sector IT que deseen mejorar la gestión del bienestar mental de sus empleados:

• Programas diferenciados por clúster

En lugar de iniciativas genéricas, diseñar intervenciones adaptadas al perfil de cada segmento. Los clústeres con baja búsqueda de tratamiento pero alta interferencia laboral requieren acciones de sensibilización y reducción del estigma.

• Mejora del apoyo institucional

Los clústeres con bajo 'support_index' indican empleados que no perciben apoyo de la empresa. Comunicar activamente los recursos disponibles (EAP, cobertura de SM) puede cambiar la percepción y el comportamiento de búsqueda de ayuda.

• Fomento de la apertura comunicativa

El 'openness_index' bajo en ciertos segmentos sugiere miedo al estigma. Programas de entrenamiento para managers y políticas explícitas de no-discriminación son clave.

• Vigilancia de perfiles de alto riesgo

Los clústeres con alta frecuencia de interferencia laboral, historial familiar y alta percepción de consecuencias negativas representan prioridad de intervención.

• Validación continua

Se recomienda re-ejecutar el análisis periódicamente para detectar cambios en la distribución de clústeres tras implementar intervenciones.

10. Conclusiones

Este análisis ha aplicado un pipeline completo de Machine Learning no supervisado al dataset OSMI Mental Health in Tech Survey (1,251 observaciones, 37 features). Los principales hallazgos son:

- Se identificaron **5 clústeres** significativos en los datos mediante K-Means, con un Silhouette Score de 0.1010, confirmando estructura latente real aunque con cierto solapamiento entre grupos.
- El preprocesamiento fue determinante: la normalización de género redujo >30 categorías a 3, la ingeniería de features construyó 3 índices sintéticos de alto valor interpretativo.
- PCA con 27 componentes (95% varianza) resolvió la maldición de la dimensionalidad, reduciendo 37 features a 27 componentes.
- K-Means demostró el mejor balance entre estabilidad y métricas. GMM ofrece una alternativa probabilística válida. DBSCAN y Spectral son menos adecuados para este tipo de datos de encuesta.
- Los clústeres revelan perfiles diferenciados que combinan apoyo institucional percibido, apertura comunicativa, prevalencia de tratamiento e interferencia laboral.
- Los resultados tienen aplicabilidad directa en el diseño de políticas de bienestar laboral personalizadas por segmento de empleados.